# Gestão de Grandes Conjuntos de Dados **2º Trabalho Prático**

Mestrado em Engenharia Informática Universidade do Minho

### Grupo nº 8

-	
PG41080	João Ribeiro Imperadeiro
PG41081	José Alberto Martins Boticas
PG41091	Nelson José Dias Teixeira
PG41851	Rui Miguel da Costa Meira

30 de maio de 2020



## Conteúdo

1	Introdução				
2	Imp	lemen	tação	4	
	2.1	Config	uração	4	
		2.1.1	Arranque do cluster	5	
		2.1.2	Execução de tarefas	7	
	2.2	$1^{\underline{a}}$ Tar	${ m refa}$	8	
		2.2.1	<i>Log</i>	8	
		2.2.2	Top3	9	
			2.2.2.1 Alternativa	9	
		2.2.3	Trending	9	
			2.2.3.1 Alternativa		
	2.3	$2^{\underline{a}}$ Tar	efa	9	
		2.3.1	<i>Top10</i>	9	
			2.3.1.1 Alternativa	10	
		2.3.2	Friends	10	
			2.3.2.1 Alternativa	11	
		2.3.3	Ratings	11	
			2.3.3.1 Alternativa		
	2.4	$3^{\underline{a}}$ Tar	efa	11	
3	Con	clusão		12	
$\mathbf{A}$	Obs	ervaçõ	ies	13	

## Lista de Figuras

2.1	Configuração - Criação da instância associada à entidade master	5
2.2	Configuração - Criação da instância associada à entidade worker1	5
2.3	Configuração - Criação da instância associada à entidade worker2	5
2.4	Configuração - swarm master	6
2.5	Configuração - swarm worker1	6
2.6	Configuração - swarm worker2	6
2.7	Configuração - Ativação do ambiente da entidade master	6
2.8	Configuração - Verificação da existência das 3 entidades do sistema	6
2.9	Configuração - Compilação do utensílio streamgen	6
2.10	Configuração - Arranque do sistema	6
2.11	Configuração - Ficheiro "docker-compose.yml" - streamgen	7
	Configuração - Verificação da disponibilidade do serviço relativo à rede $\textit{mystack\_default}$	7
	Configuração - Acesso à plataforma $Hadoop\ HDFS$	7
2.14	Configuração - Obtenção do ficheiro jar do projeto	7
2.15	Configuração - Dockerfile	8
2.16	Configuração - Opções de execução do ficheiro <i>Dockerfile</i>	8
2.17	$2^{\underline{a}}$ Tarefa $(batch)$ - Esquema do processamento relativo à subtarefa $Top10$	10
2.18	$2^{a}$ Tarefa ( $batch$ ) - Esquema do processamento relativo à subtarefa $Friends$	11

### Capítulo 1

## Introdução

Neste trabalho prático é requerida a concretização e avaliação experimental de tarefas de armazenamento e processamento de dados através do uso da ferramenta computacional *Spark* (*batch* e *streaming*). Por forma a realizar estas tarefas, são utilizados os dados públicos do *IMDb*, que se encontram disponíveis em:

Para além destes dados, é também utilizado um gerador de *streams*, baseado nos mesmos, que simula uma sequência de votos individuais de utilizadores. Este utensílio foi desenvolvido pelo docente desta unidade curricular e encontra-se disponível na plataforma *Blackboard*.

Ao longo deste documento vão também ser expostos todos os passos tomados durante a implementação das tarefas pedidas neste projeto, incluindo as decisões tomadas pelos elementos deste grupo a nível de algoritmos e parâmetros de configuração. Para além disso são ainda apresentadas todas as instruções que permitem executar e utilizar corretamente os programas desenvolvidos. Por fim, na fase final deste manuscrito, são exibidos os objetivos atingidos após a realização das tarefas propostas.

De salientar também que durante os capítulos que se seguem são identificadas algumas alternativas para concretizar as tarefas indicadas neste trabalho prático.

### Capítulo 2

## Implementação

Para a realização com sucesso deste trabalho prático, é solicitada a elaboração de três tarefas. Apresentam-se de seguida as mesmas:

- 1. Desenvolver uma componente de processamento de *streams* que produza os seguintes resultados:
  - *Log*: armazenar todos os votos individuais recebidos, etiquetados com a hora de chegada aproximada ao minuto, em lotes de 10 minutos. Cada lote deve ser guardado num ficheiro cujo nome identifica o período de tempo;
  - *Top3*: exibir a cada minuto o *top* 3 dos títulos que obtiveram melhor classificação média nos últimos 10 minutos;
  - *Trending*: apresentar a cada 15 minutos os títulos em que o número de votos recolhido nesse período sejam superiores aos votos obtidos no período anterior, independentemente do valor dos votos.
- 2. Implementar uma componente de processamento em *batch* que permita realizar as seguintes tarefas:
  - *Top10*: calcular o *top* 10 dos atores que participaram em mais títulos diferentes:
  - *Friends*: computar o conjunto de colaboradores de cada ator (i.e., outros atores que participaram nos mesmos títulos);
  - Ratings: atualizar o ficheiro "title.ratings.tsv" tendo em conta o seu conteúdo anterior e os novos votos recebidos até ao momento.
- 3. Escolher a configuração e a implementação que, para o mesmo *hardware*, permite receber e tratar o maior débito de eventos. Esta tomada de decisão deve ser devidamente justificada com recurso a resultados experimentais.

Nas próximas secções são evidenciadas as implementações para cada uma destas tarefas bem como algumas sugestões alternativas que poderiam ser tomadas em consideração.

### 2.1 Configuração

Nesta secção do relatório são apresentadas as configurações relativas ao arranque do *cluster*, instanciando-se tanto as respetivas entidades (*master*, *worker1* e *worker2*) como as máquinas virtuais pertencentes à plataforma *Google Cloud*, e, ainda, a configuração genérica para a execução individual de cada exercício proposto.

#### 2.1.1 Arranque do cluster

A configuração escolhida para a realização deste projeto coincide com a que foi sugerida pelo docente desta unidade curricular, isto é, o docker swarm. Esta configuração permite não só tirar partido da ferramenta computacional Google Cloud como também possibilita o uso de plataformas como o Hadoop HDFS e o Apache Spark. Como seria de esperar, todos os ficheiros de input utilizados para atingir os objetivos traçados neste trabalho prático são armazenados no sistema Hadoop HDFS. Exibe-se de seguida todos os passos de configuração associados ao docker swarm:

1. criação das instâncias relativas às 3 entidades intrínsecas à arquitetura do sistema, isto é, as entidades master, worker1 e worker2:

```
docker-machine create \
--driver google --google-project ferrous-aleph-271712 \
--google-zone europe-west1-b \
--google-machine-type n1-standard-2 \
--google-disk-size=100 \
--google-disk-type=pd-ssd \
--google-machine-image \
https://www.googleapis.com/compute/v1/projects/centos-cloud/global/images/centos-7-v20200309 \
master
```

Figura 2.1: Configuração - Criação da instância associada à entidade master

Figura 2.2: Configuração - Criação da instância associada à entidade worker1

```
docker-machine create \
--driver google --google-project ferrous-aleph-271712 \
--google-zone europe-west1-b \
--google-machine-type n1-standard-2 \
--google-disk-size=100 \
--google-disk-type=pd-ssd \
--google-machine-image \
https://www.googleapis.com/compute/v1/projects/centos-cloud/global/images/centos-7-v20200309 \
worker2
```

Figura 2.3: Configuração - Criação da instância associada à entidade worker2

De salientar que a designação ferrous-aleph-271712 corresponde ao identificador do projeto presente na plataforma *Google Cloud* de um dos elementos que compõem este grupo. Assim, esta denominação deve ser substituída pelo nome do projeto do utilizador em causa.

2. configuração do swarm relativo às entidades master, worker1 e worker2:

```
docker-machine ssh master sudo docker swarm init
```

Figura 2.4: Configuração - swarm master

```
docker-machine ssh worker1 sudo docker swarm join --token \
SWMTKN-1-5zfy2iio54tma997pnt96gq5095fimqn2hxr2a8j16ogq0n3c9-0kp6mi5iuj956gp19sfccd5bo\
10.132.0.8:2377
```

Figura 2.5: Configuração - swarm worker1

```
docker-machine ssh worker2 sudo docker swarm join --token \
SWMTKN-1-5zfy2iio54tma997pnt96gq5095fimqn2hxr2a8j16ogq0n3c9-0kp6mi5iuj956gpl9sfccd5bo\
10.132.0.8:2377
```

Figura 2.6: Configuração - swarm worker2

3. ativação do ambiente da entidade master:

```
docker-machine env master
eval $(docker-machine env master)
```

Figura 2.7: Configuração - Ativação do ambiente da entidade master

**4.** verificação da existência das 3 entidades presentes no sistema e das respetivas propriedades:

```
docker node 1s
```

Figura 2.8: Configuração - Verificação da existência das 3 entidades do sistema

5. compilação do gerador de *streams*, isto é, o *streamgen*:

```
mvn package
docker build -t streamgen .
```

Figura 2.9: Configuração - Compilação do utensílio streamgen

**6.** arranque do sistema com a configuração swarm especificada:

```
docker stack deploy -c ../swarm-spark/docker-compose.yml mystack
```

Figura 2.10: Configuração - Arranque do sistema

É de realçar que no ficheiro "docker-compose.yml" encontra-se uma configuração docker semelhante à que foi utilizada no guião nº 8 desta unidade curricular. A única diferença presente no mesmo diz respeito à integração do gerador de streams (streamgen) desenvolvido pelo docente como um container docker do sistema. Assim, no momento do arranque do sistema, a ferramenta streamgen é convenientemente invocada, ficando à espera de novas conexões por parte dos utilizadores. Apresenta-se de seguida a configuração presente no ficheiro "docker-compose.yml" relativa ao streamgen:

```
streamgen:
1
         image: streamgen
2
         command: hdfs:///data/title.ratings.tsv 120
3
4
              - ./hadoop.env
         deploy:
6
             mode: replicated
             replicas: 1
             placement:
9
                  constraints:
10
                      - "node.role==manager"
11
```

Figura 2.11: Configuração - Ficheiro "docker-compose.yml" - streamgen

7. verificação da disponibilidade do serviço relativo à rede *mystack default*:

```
docker stack ls
docker service ls
docker network ls
```

Figura 2.12: Configuração - Verificação da disponibilidade do serviço relativo à rede mystack default

8. acesso à plataforma *Hadoop HDFS* por parte do utilizador:

```
docker run --network mystack_default --env-file ../swarm-spark/hadoop.env -it bde2020/hadoop-base \
bash
```

Figura 2.13: Configuração - Acesso à plataforma Hadoop HDFS

Com a concretização dos 8 passos descritos acima fica concluída a configuração associada à ferramenta docker swarm.

#### 2.1.2 Execução de tarefas

Para a execução dos 6 exercícios descritos na secção relativa à implementação, é disponibilizado um ficheiro com a designação *Dockerfile*. Neste é especificado o nome da classe relativa à proposta que se presente executar, procedendo corretamente à sua invocação. Como tal, em primeiro lugar é preciso desempenhar a seguinte instrução:

```
nwn package
```

Figura 2.14: Configuração - Obtenção do ficheiro jar do projeto

De seguida, invoca-se o dockerfile em causa. Expõe-se agora o seu conteúdo:

```
FROM bde2020/spark-base:2.4.4-hadoop2.7

COPY target/TP2-1.0-SNAPSHOT.jar /

ENTRYPOINT ["/spark/bin/spark-submit", "--class", "package.className", "--master", \

"spark://spark-master:7077", "/TP2-1.0-SNAPSHOT.jar"]
```

Figura 2.15: Configuração - Dockerfile

A este ficheiro estão associadas alguma opções de execução que garantem uma comunicação fidedigna com o sistema inicialmente declarado. Eis as mesmas:

```
-p 4040:4040 --network mystack_default --env-file ../swarm-spark/hadoop.env
```

Figura 2.16: Configuração - Opções de execução do ficheiro Dockerfile

De salientar que é escolhida a opção *master* no campo relativo ao *docker machine* para, mais uma vez, garantir uma configuração válida do sistema em causa.

#### $2.2 ext{1}^{\underline{\mathbf{a}}}$ Tarefa

Na 1ª tarefa deste projeto é pedido o desenvolvimento de uma componente de processamento de *streams*. Nesta é solicitada a realização de vários exercícios com diferentes caraterísticas. Como tal, apresenta-se de seguida as respetivas implementações e, ainda, possíveis alternativas nas suas concretizações.

#### 2.2.1 Log

Neste exercício, tal como foi indicado anteriormente neste capítulo, é imposto o armazenamento de todos os votos individuais recebidos com a indicação da hora de chegada aproximada ao minuto, em lotes de 10 minutos, sendo que cada lote é guardado com o nome relativo ao período de tempo em causa.

Dito isto, para proceder ao tratamento da aproximação da hora recebida ao minuto, foi implementada uma função para o efeito. O grupo optou por não só guardar a hora referida como também a data em questão, exibindo, desta forma, um maior detalhe da informação recebida. Uma vez implementada esta função, seguindo a sugestão fornecida pelo docente desta unidade curricular, foi utilizado o método transform que faz uso da noção de tempo. Com esta vertente, é possível associar a cada rdd do conjunto de dados o tempo exato em que este foi processado.

Por fim, com os aspetos computacionais mencionados acima, resta armazenar os dados recebidos pela ferramenta streamgen com recurso à definição de uma janela que respeite o enunciado deste exercício, isto é, 10 minutos de duração e 10 minutos de deslocamento. Os rdd's em causa são guardados na diretoria Log/Lot{i} - dd-MM-yyyy HH-mm, sendo que i diz respeito ao número do lote (que começa no número 1 e que é constamente incrementado) e dd-MM-yyyy HH-mm refere-se ao padrão do período temporal. De maneira a coletar num só ficheiro (part-00000) todos os rdd's referentes a este exercício, foi aplicado o método coalesce(1). Esta última função, quando comparada com a repartition(), não necessita de efetuar um shuffle completo dos dados e, para além disso, é mais otimizada para a redução do número de partições. Para além disto, esta abordagem foi considerada nesta implementação

dado que no exercício *Ratings* (batch) será necessário realizar a leitura do ficheiro mencionado. Consequentemente, em vez de operar várias leituras de ficheiros associados a rdd's, efetua-se apenas uma leitura, permitindo, assim, uma maior eficiência.

- 2.2.2 *Top3*
- 2.2.2.1 Alternativa
- 2.2.3 Trending
- 2.2.3.1 Alternativa

#### $2.3 \quad 2^{\underline{a}} \text{ Tarefa}$

Na 2ª tarefa deste trabalho prático é proposta a implementação de uma componente de processamento em *batch*. Nesta é solicitada a realização de 3 exercícios com diferentes caraterísticas e, como tal, foram adotapadas abordagens distintas para cada um deles. Divulga-se de seguida as respetivas implementações.

#### 2.3.1 Top10

Tal como foi mencionado no início  $2^{0}$  capítulo, nesta subtarefa é pedido o cálculo dos 10 atores que participaram em mais filmes distintos.

Durante o processamento inicial do ficheiro "title.principals.tsv" é, tal como seria de esperar, ignorado o respetivo cabeçalho. Posteriormente, é extraída, linha após linha, a informação pertinente do mesmo, isto é, os identificadores do filme e do ator em questão, agrupando os dados pela segunda componente. Esta última ação é efetuada com recurso à chamada do método groupByKey. Uma vez realizada esta computação, obtém-se para cada ator a lista de filmes em que este participou. Atendendo ao resultado exigido neste exercício, basta, nesta etapa do processamento, efetuar a contagem dos filmes associados a cada ator, filtrando os 10 registos com maiores valores.

A recolha dos 10 atores que participaram em mais filmes é formalizada com a chamada do método top. Esta função permite extrair os k maiores registos de um RDD segundo uma determinada ordem. Para o caso deste exercício, houve a necessidade de implementar um comparador explícito, numa classe à parte, dado que o tipo de dados Tuple2 não é, por definição, serializável.

Tendo em consideração este último detalhe, conclui-se a realização desta subtarefa.

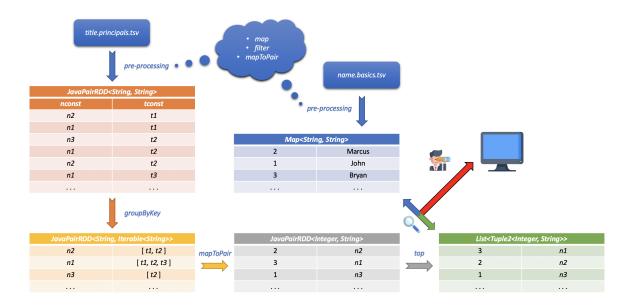


Figura 2.17:  $2^{\underline{a}}$  Tarefa (batch) - Esquema do processamento relativo à subtarefa Top 10

#### 2.3.1.1 Alternativa

Uma forma alternativa de resolver este exercício seria, na última fase do processamento, utilizar o método take em detrimento da função top. Esta escolha não foi tomada em consideração na implementação uma vez que o primeiro método necessita previamente que a informação esteja devidamente ordenada. Esta ordenação teria de ser realizada com a invocação do método sortByKey(false), colocando a contagem dos filmes em que cada ator participou de forma decrescente. Este último facto representa uma ineficiência no cálculo do resultado pretendido uma vez que é efetuada a ordenação completa da informação em causa e, para além disso, realiza-se desnecessariamente um passo computacional extra.

#### 2.3.2 Friends

Neste exercício é requerido a computação do conjunto de colaboradores associado a cada ator, ou seja, o grupo dos atores que particapam nos mesmos filmes.

Durante o processamento inicial do ficheiro "title.principals.tsv" é, tal como seria de esperar, ignorado o respetivo cabeçalho. Posteriormente, é extraída, linha após linha, a informação pertinente do mesmo, isto é, os identificadores do filme e do ator em questão, agrupando os dados pela primeira componente. Esta última ação é efetuada com recurso à chamada do método groupByKey. De forma a obter o resultado solicitado nesta subtarefa, é necessário, nesta fase da computação, proceder à realização de uma operação denominada por produto cartesiano. Nesta operação computa-se, num dado momento, vários pares de atores que coloboraram num determinado filme. Uma vez realizado este cálculo, é invocado novamente o método groupByKey de forma a obter o resultado pretendido, isto é, o conjunto de colaboradores para cada ator presente nos dados públicos do IMDb.

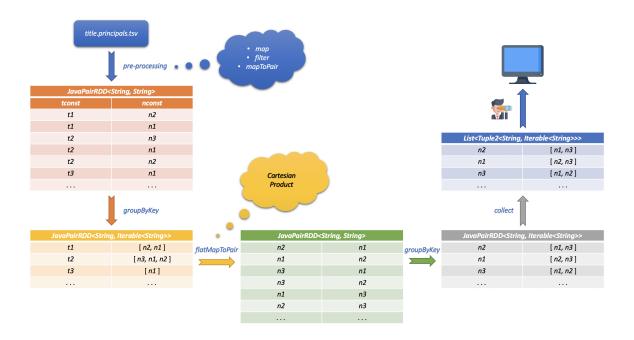


Figura 2.18:  $2^{\underline{a}}$  Tarefa (batch) - Esquema do processamento relativo à subtarefa Friends

- 2.3.2.1 Alternativa
- $2.3.3 \quad Ratings$
- 2.3.3.1 Alternativa
- $2.4 \quad 3^{\underline{a}} \text{ Tarefa}$

## Capítulo 3

## Conclusão

## Apêndice A

## Observações

Documentação Java 8: https://docs.oracle.com/javase/8/docs/api/
Maven: https://maven.apache.org/

• Docker:

https://www.docker.com/

• Apache Spark:

https://spark.apache.org/

• Apache Hadoop:

http://hadoop.apache.org/