Gestão de Grandes Conjuntos de Dados

2º Trabalho Prático

-

Mestrado em Engenharia Informática
Universidade do Minho

Grupo nº 8	
PG41080	João Ribeiro Imperadeiro
PG41081	José Alberto Martins Boticas
PG41091	Nelson José Dias Teixeira
PG41851	Rui Miguel da Costa Meira

30 de maio de 2020

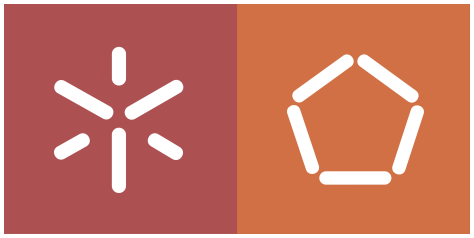

Conteúdo

Lista de Figuras

Capítulo 1

Introdução

Neste trabalho prático é requerida a concretização e avaliação experimental de tarefas de armazenamento e processamento de dados através do uso da ferramenta computacional *Spark* (*batch* e *streaming*). Por forma a realizar estas tarefas, são utilizados os dados públicos do *IMDb*, que se encontram disponíveis em:

https://www.imdb.com/interfaces/

Para além destes dados, é também utilizado um gerador de *streams*, baseado nos mesmos, que simula uma sequência de votos individuais de utilizadores. Este utensílio foi desenvolvido pelo docente desta unidade curricular e encontra-se disponível na plataforma *Blackboard*.

Ao longo deste documento vão também ser expostos todos os passos tomados durante a implementação das tarefas pedidas neste projeto, incluindo as decisões tomadas pelos elementos deste grupo a nível de algoritmos e parâmetros de configuração. Para além disso são ainda apresentadas todas as instruções que permitem executar e utilizar corretamente os programas desenvolvidos. Por fim, na fase final deste manuscrito, são exibidos os objetivos atingidos após a realização das tarefas propostas.

De salientar também que durante os capítulos que se seguem são identificadas algumas alternativas para concretizar as tarefas indicadas neste trabalho prático.

Capítulo 2

Implementação

Para a realização com sucesso deste trabalho prático, é solicitada a elaboração de três tarefas. Apresentam-se de seguida as mesmas:

1. Desenvolver uma componente de processamento de *streams* que produza os seguintes resultados:
   - ***Log***: armazenar todos os votos individuais recebidos, etiquetados com a hora de chegada aproximada ao minuto, em lotes de 10 minutos. Cada lote deve ser guardado num ficheiro cujo nome identifica o período de tempo;
   - ***Top3***: exibir a cada minuto o *top* 3 dos títulos que obtiveram melhor classificação média nos últimos 10 minutos;
   - ***Trending***: apresentar a cada 15 minutos os títulos em que o número de votos recolhido nesse período sejam superiores aos votos obtidos no período anterior, independentemente do valor dos votos.
2. Implementar uma componente de processamento em *batch* que permita realizar as seguintes tarefas:
   - ***Top10***: calcular o *top* 10 dos atores que participaram em mais títulos diferentes;
   - ***Friends***: computar o conjunto de colaboradores de cada ator (i.e., outros atores que participaram nos mesmos títulos);
   - ***Ratings***: atualizar o ficheiro *"title.ratings.tsv"* tendo em conta o seu conteúdo anterior e os novos votos recebidos até ao momento.
3. Escolher a configuração e a implementação que, para o mesmo *hardware*, permite receber e tratar o maior débito de eventos. Esta tomada de decisão deve ser devidamente justificada com recurso a resultados experimentais.

Nas próximas secções são evidenciadas as implementações para cada uma destas tarefas bem como algumas sugestões alternativas que poderiam ser tomadas em consideração.

2.1 Configuração

Nesta secção do relatório são apresentadas as configurações relativas ao arranque do *cluster*, instanciando-se tanto as respetivas entidades (*master*, *worker1* e *worker2*) como as máquinas virtuais pertencentes à plataforma *Google Cloud*, e, ainda, a configuração genérica para a execução individual de cada exercício proposto.

2.1.1 Arranque do *cluster*

A configuração escolhida para a realização deste projeto coincide com a que foi sugerida pelo docente desta unidade curricular, isto é, o ***docker swarm***. Esta configuração permite não só tirar partido da ferramenta computacional *Google Cloud* como também possibilita o uso de plataformas como o *Hadoop HDFS* e o *Apache Spark*. Como seria de esperar, todos os ficheiros de *input* utilizados para atingir os objetivos traçados neste trabalho prático são armazenados no sistema *Hadoop HDFS*.

Exibe-se de seguida todos os passos de configuração associados ao *docker swarm*:

1. criação das instâncias relativas às 3 entidades intrínsecas à arquitetura do sistema, isto é, as entidades *master*, *worker1* e *worker2*:

```
docker-machine create \
               --driver google --google-project ferrous-aleph-271712 \
               --google-zone europe-west1-b \
               --google-machine-type n1-standard-2 \
               --google-disk-size=100 \
               --google-disk-type=pd-ssd \
               --google-machine-image \
       https://www.googleapis.com/compute/v1/projects/centos-cloud/global/images/centos-7-v20200309 \
               master
```

Figura 2.1: Configuração - Criação da instância associada à entidade *master*

```
docker-machine create \
               --driver google --google-project ferrous-aleph-271712 \
               --google-zone europe-west1-b \
               --google-machine-type n1-standard-2 \
               --google-disk-size=100 \
               --google-disk-type=pd-ssd \
               --google-machine-image \
       https://www.googleapis.com/compute/v1/projects/centos-cloud/global/images/centos-7-v20200309 \
               worker1
```

Figura 2.2: Configuração - Criação da instância associada à entidade *worker1*

```
docker-machine create \
               --driver google --google-project ferrous-aleph-271712 \
               --google-zone europe-west1-b \
               --google-machine-type n1-standard-2 \
               --google-disk-size=100 \
               --google-disk-type=pd-ssd \
               --google-machine-image \
       https://www.googleapis.com/compute/v1/projects/centos-cloud/global/images/centos-7-v20200309 \
               worker2
```

Figura 2.3: Configuração - Criação da instância associada à entidade *worker2*

   De salientar que a designação `ferrous-aleph-271712` corresponde ao identificador do projeto presente na plataforma *Google Cloud* de um dos elementos que compõem este grupo. Assim, esta denominação deve ser substituída pelo nome do projeto do utilizador em causa.

2. configuração do *swarm* relativo às entidades *master*, *worker1* e *worker2*:

```
docker-machine ssh master sudo docker swarm init
```

Figura 2.4: Configuração - *swarm master*

```
docker-machine ssh worker1 sudo docker swarm join --token \
               SWMTKN-1-5zfy2iio54tma997pnt96gq5095fimqn2hxr2a8j16ogq0n3c9-0kp6mi5iuj956gpl9sfccd5bo\
               10.132.0.8:2377
```

Figura 2.5: Configuração - *swarm worker1*

```
docker-machine ssh worker2 sudo docker swarm join --token \
               SWMTKN-1-5zfy2iio54tma997pnt96gq5095fimqn2hxr2a8j16ogq0n3c9-0kp6mi5iuj956gpl9sfccd5bo\
               10.132.0.8:2377
```

Figura 2.6: Configuração - *swarm worker2*

3. ativação do ambiente da entidade *master*:

```
docker-machine env master
eval $(docker-machine env master)
```

Figura 2.7: Configuração - Ativação do ambiente da entidade *master*

4. verificação da existência das 3 entidades presentes no sistema e das respetivas propriedades:

```
docker node ls
```

Figura 2.8: Configuração - Verificação da existência das 3 entidades do sistema

5. compilação do gerador de *streams*, isto é, o *streamgen*:

```
mvn package
docker build -t streamgen .
```

Figura 2.9: Configuração - Compilação do utensílio *streamgen*

6. arranque do sistema com a configuração *swarm* especificada:

```
docker stack deploy -c ../swarm-spark/docker-compose.yml mystack
```

Figura 2.10: Configuração - Arranque do sistema

É de realçar que no ficheiro *"docker-compose.yml"* encontra-se uma configuração *docker* semelhante à que foi utilizada no guião nº 8 desta unidade curricular. A única diferença presente no mesmo diz respeito à integração do gerador de *streams* (*streamgen*) desenvolvido pelo docente como um *container docker* do sistema. Assim, no momento do arranque do sistema, a ferramenta *streamgen* é convenientemente invocada, ficando à espera de novas conexões por parte dos utilizadores. Apresenta-se de seguida a configuração presente no ficheiro *"docker-compose.yml"* relativa ao *streamgen*:

```
streamgen:
    image: streamgen
    command: hdfs:///data/title.ratings.tsv 120
    env_file:
        - ./hadoop.env
    deploy:
        mode: replicated
        replicas: 1
        placement:
            constraints:
                - "node.role==manager"
```

Figura 2.11: Configuração - Ficheiro *"docker-compose.yml"* - *streamgen*

7. verificação da disponibilidade do serviço relativo à rede *mystack_ default*:

```
docker stack ls
docker service ls
docker network ls
```

Figura 2.12: Configuração - Verificação da disponibilidade do serviço relativo à rede *mystack_ default*

8. acesso à plataforma *Hadoop HDFS* por parte do utilizador:

```
docker run --network mystack_default --env-file ../swarm-spark/hadoop.env -it bde2020/hadoop-base \
       bash
```

Figura 2.13: Configuração - Acesso à plataforma *Hadoop HDFS*

Com a concretização dos 8 passos descritos acima fica concluída a configuração associada à ferramenta *docker swarm*.

2.1.2 Execução de tarefas

Para a execução dos 6 exercícios descritos na secção relativa à implementação, é disponibilizado um ficheiro com a designação *Dockerfile*. Neste é especificado o nome da classe relativa à proposta que se presente executar, procedendo corretamente à sua invocação. Como tal, em primeiro lugar é preciso desempenhar a seguinte instrução:

```
mvn package
```

Figura 2.14: Configuração - Obtenção do ficheiro *jar* do projeto

De seguida, invoca-se o *dockerfile* em causa. Expõe-se agora o seu conteúdo:

```
FROM bde2020/spark-base:2.4.4-hadoop2.7
COPY target/TP2-1.0-SNAPSHOT.jar /
ENTRYPOINT ["/spark/bin/spark-submit", "--class", "package.className", "--master", \
            "spark://spark-master:7077", "/TP2-1.0-SNAPSHOT.jar"]
```

Figura 2.15: Configuração - *Dockerfile*

A este ficheiro estão associadas alguma opções de execução que garantem uma comunicação fidedigna com o sistema inicialmente declarado. Eis as mesmas:

```
-p 4040:4040 --network mystack_default --env-file ../swarm-spark/hadoop.env
```

Figura 2.16: Configuração - Opções de execução do ficheiro *Dockerfile*

De salientar que é escolhida a opção *master* no campo relativo ao *docker machine* para, mais uma vez, garantir uma configuração válida do sistema em causa.

2.2 1ª Tarefa

Na 1ª tarefa deste projeto é pedido o desenvolvimento de uma componente de processamento de *streams*. Nesta é solicitada a realização de vários exercícios com diferentes caraterísticas. Como tal, apresenta-se de seguida as respetivas implementações e, ainda, possíveis alternativas nas suas concretizações.

2.2.1 *Log*

Neste exercício, tal como foi indicado anteriormente neste capítulo, é imposto o armazenamento de todos os votos individuais recebidos com a indicação da hora de chegada aproximada ao minuto, em lotes de 10 minutos, sendo que cada lote é guardado com o nome relativo ao período de tempo em causa.

Dito isto, para proceder ao tratamento da aproximação da hora recebida ao minuto, foi implementada uma função para o efeito. O grupo optou por não só guardar a hora referida como também a data em questão, exibindo, desta forma, um maior detalhe da informação recebida. Uma vez implementada esta função, seguindo a sugestão fornecida pelo docente desta unidade curricular, foi utilizado o método *transform* que faz uso da noção de tempo. Com esta vertente, é possível associar a cada *rdd* do conjunto de dados o tempo exato em que este foi processado.

Por fim, com os aspetos computacionais mencionados acima, resta armazenar os dados recebidos pela ferramenta *streamgen* com recurso à definição de uma janela que respeite o enunciado deste exercício, isto é, 10 minutos de duração e 10 minutos de deslocamento. Os *rdd's* em causa são guardados na diretoria `Log/Lot{i} - dd-MM-yyyy HH-mm`, sendo que `i` diz respeito ao número do lote (que começa no número 1 e que é constamente incrementado) e `dd-MM-yyyy HH-mm` refere-se ao padrão do período temporal. De maneira a coletar num só ficheiro (*part-00000*) todos os *rdd's* referentes a este exercício, foi aplicado o método *coalesce(1)*. Esta última função, quando comparada com a *repartition()*, não necessita de efetuar um *shuffle* completo dos dados e, para além disso, é mais otimizada para a redução do número de partições. Para além disto, esta abordagem foi considerada nesta implementação

dado que no exercício *Ratings* (*batch*) será necessário realizar a leitura do ficheiro mencionado. Consequentemente, em vez de operar várias leituras de ficheiros associados a *rdd's*, efetua-se apenas uma leitura, permitindo, assim, uma maior eficiência.

2.2.2 *Top3*

2.2.2.1 Alternativa

2.2.3 *Trending*

2.2.3.1 Alternativa

2.3 2ª Tarefa

Na 2ª tarefa deste trabalho prático é proposta a implementação de uma componente de processamento em *batch*. Nesta é solicitada a realização de 3 exercícios com diferentes caraterísticas e, como tal, foram adotapadas abordagens distintas para cada um deles. Divulga-se de seguida as respetivas implementações.

2.3.1 *Top10*

Tal como foi mencionado no início 2º capítulo, nesta subtarefa é pedido o cálculo dos 10 atores que participaram em mais filmes distintos.

Durante o processamento inicial do ficheiro *"title.principals.tsv"* é, tal como seria de esperar, ignorado o respetivo cabeçalho. Posteriormente, é extraída, linha após linha, a informação pertinente do mesmo, isto é, os identificadores do filme e do ator em questão, agrupando os dados pela segunda componente. Esta última ação é efetuada com recurso à chamada do método *groupByKey*. Uma vez realizada esta computação, obtém-se para cada ator a lista de filmes em que este participou. Atendendo ao resultado exigido neste exercício, basta, nesta etapa do processamento, efetuar a contagem dos filmes associados a cada ator, filtrando os 10 registos com maiores valores.

A recolha dos 10 atores que participaram em mais filmes é formalizada com a chamada do método *top*. Esta função permite extrair os k maiores registos de um *RDD* segundo uma determinada ordem. Para o caso deste exercício, houve a necessidade de implementar um comparador explícito, numa classe à parte, dado que o tipo de dados *Tuple2* não é, por definição, serializável.

Tendo em consideração este último detalhe, conclui-se a realização desta subtarefa.

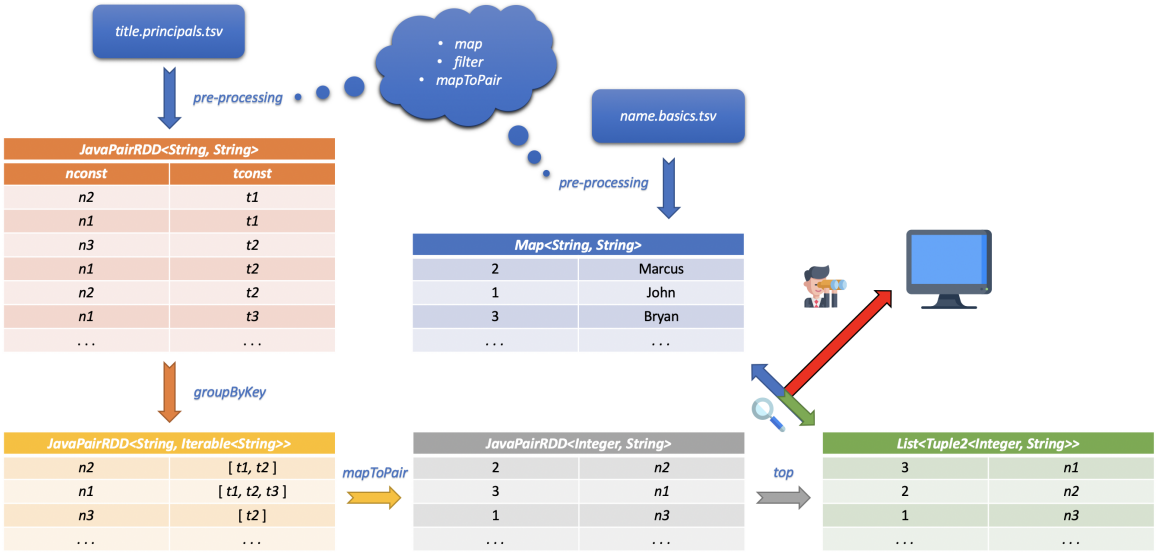

Figura 2.17: 2ª Tarefa (*batch*) - Esquema do processamento relativo à subtarefa *Top10*

2.3.1.1 Alternativa

Uma forma alternativa de resolver este exercício seria, na última fase do processamento, utilizar o método *take* em detrimento da função *top*. Esta escolha não foi tomada em consideração na implementação uma vez que o primeiro método necessita previamente que a informação esteja devidamente ordenada. Esta ordenação teria de ser realizada com a invocação do método *sortByKey(false)*, colocando a contagem dos filmes em que cada ator participou de forma decrescente. Este último facto representa uma ineficiência no cálculo do resultado pretendido uma vez que é efetuada a ordenação completa da informação em causa e, para além disso, realiza-se desnecessariamente um passo computacional extra.

2.3.2 *Friends*

Neste exercício é requerido a computação do conjunto de colaboradores associado a cada ator, ou seja, o grupo dos atores que particapam nos mesmos filmes.

Durante o processamento inicial do ficheiro *"title.principals.tsv"* é, tal como seria de esperar, ignorado o respetivo cabeçalho. Posteriormente, é extraída, linha após linha, a informação pertinente do mesmo, isto é, os identificadores do filme e do ator em questão, agrupando os dados pela primeira componente. Esta última ação é efetuada com recurso à chamada do método *groupByKey*. De forma a obter o resultado solicitado nesta subtarefa, é necessário, nesta fase da computação, proceder à realização de uma operação denominada por produto cartesiano. Nesta operação computa-se, num dado momento, vários pares de atores que coloboraram num determinado filme. Uma vez realizado este cálculo, é invocado novamente o método *groupByKey* de forma a obter o resultado pretendido, isto é, o conjunto de colaboradores para cada ator presente nos dados públicos do *IMDb*.

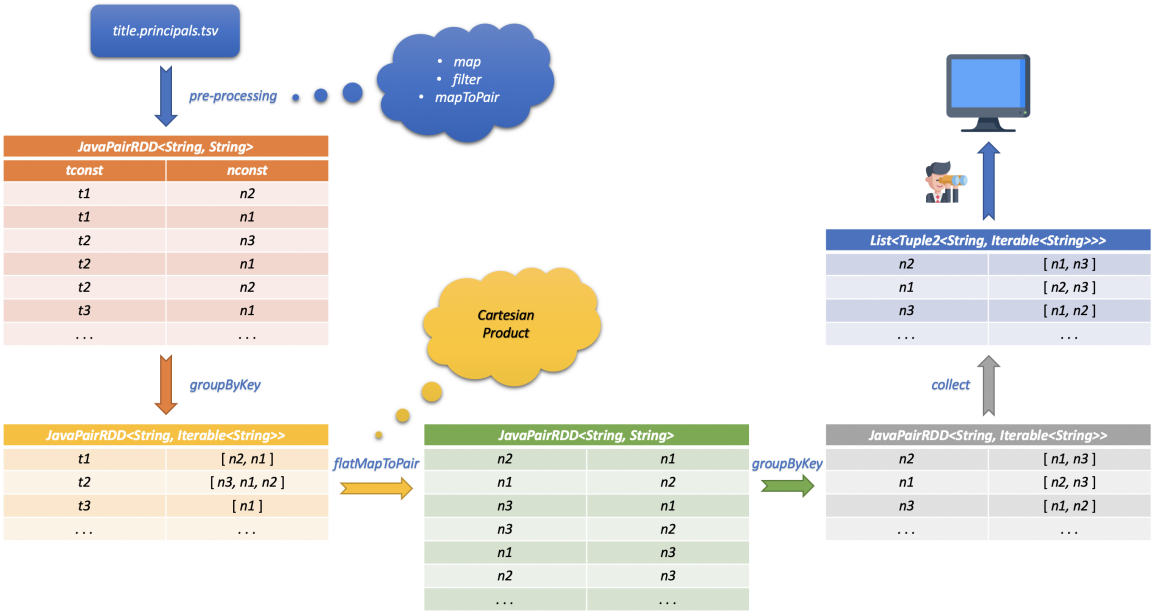

Figura 2.18: 2ª Tarefa (*batch*) - Esquema do processamento relativo à subtarefa *Friends*

2.3.2.1 Alternativa

2.3.3 *Ratings*

2.3.3.1 Alternativa

2.4 3ª Tarefa

Capítulo 3

Conclusão

Apêndice A

Observações

- Documentação *Java* 8:
  https://docs.oracle.com/javase/8/docs/api/
- *Maven*:
  https://maven.apache.org/
- *Docker*:
  https://www.docker.com/
- *Apache Spark*:
  https://spark.apache.org/
- *Apache Hadoop*:
  http://hadoop.apache.org/